

Modelagem paramétrica para projeto inteligente e automatizado de fundações superficiais do tipo sapata: Pré dimensionamento, projeto automatizado e confiabilidade

Filipe Amaral Pereira^a, Wanderlei M. Pereira Junior^{a, b, c}, Lucas Teixeira Correia^d

^a*Federal University of Catalão, Engineering College, Av. Dr. Lamartine Pinto de Avelar, 1120, Catalão, 75704-020, Brazil*

^b*University of São Paulo – School of Engineering of São Carlos, Av. Trabalhador São Carlense, 400 – Parque Arnold Schmidt, São Carlos – SP, 13566-590, Brazil*

^c*Federal University of Goiás – School of Civil and Environmental Engineering, Avenida Universitária, Quadra 86, Lote Área 1488 – Setor Leste Universitário, Goiânia – GO, 74605-220, Brazil*

^d*Pontifical Catholic University of Goiás – School of Engineering, Avenida Universitária, 1440 – Setor Universitário, Goiânia – GO, 74605-010, Brazil*

Abstract

O dimensionamento de fundações superficiais do tipo sapata isolada é predominantemente realizado por procedimentos iterativos baseados na experiência do projetista, resultando frequentemente em soluções conservadoras e, conseqüentemente, em elevado consumo de materiais. Este artigo apresenta uma metodologia computacional que integra critérios estruturais, geotécnicos e geométricos em um único ambiente de projeto para o dimensionamento automatizado e otimizado de sapatas isoladas. A formulação adota, como função objetivo, a minimização do volume de concreto, sujeita a restrições baseadas nas normas brasileiras NBR 6118 e NBR 6122, que abrangem tensões no solo, punção, compatibilidade geométrica entre o pilar e a sapata, e sobreposição entre elementos de fundação. O problema de otimização mono-objetivo é resolvido por meio do método Efficient Global Optimization (EGO), que combina um modelo substituto baseado em regressão por processos gaussianos (*Kriging*) com uma função de aquisição (*Expected Improvement*) para equilibrar exploração e intensificação da busca. Um algoritmo genético (AG) é empregado como otimizador interno para maximizar a função de aquisição. A metodologia foi implementada em uma plataforma *web* (FUNDAAI) e aplicada a diferentes exemplos de projetos com um, dois e três elementos de fundação. Os resultados do trabalho demonstraram que o EGO é capaz de convergir para soluções viáveis, mesmo com o aumento da dimensionalidade do problema. A ferramenta proposta alcançou reduções médias de 40,79% no volume de concreto em comparação com simulações de Monte Carlo, que foram aplicadas para representar práticas tradicionais de tentativa e erro de escritórios, atingindo até 85,87% em casos específicos. Através da análise das razões solicitação/resistência, foi possível identificar as restrições governantes em cada configuração, evidenciando que a otimização global pode levar a soluções nas quais nem todos os elementos atingem seus limites individuais. Em situações com alto grau de proximidade entre sapatas, a verificação de sobreposição mostrou-se eficiente na identificação, embora a metodologia atual seja mais adequada a arranjos sem interferências severas. Conclui-se que a ferramenta desenvolvida tem potencial para se tornar uma alternativa eficaz para o projeto racional de fundações, contribuindo para a redução do consumo de materiais, a diminuição dos impactos ambientais associados, a padronização e a redução do esforço do processo de dimensionamento.

Keywords:

Otimização de sapatas, Efficient Global Optimization (EGO), Algoritmo genético (AG),

1. Introdução

O dimensionamento de fundações rasas constitui uma etapa fundamental no projeto de estruturas de concreto armado, sendo responsável por assegurar a transferência adequada das ações da superestrutura ao maciço de solo de apoio. O desempenho dessas fundações está diretamente associado à segurança global da edificação, à limitação de recalques diferenciais e à preservação da integridade de construções vizinhas [1]. No contexto brasileiro, o avanço do processo de urbanização tem imposto desafios adicionais ao projeto de fundações, em especial em áreas consolidadas, caracterizadas por terrenos reduzidos, geometrias irregulares e edificações implantadas em proximidade imediata. Dados de 2022 indicam que 87,4 % da população brasileira residia em áreas urbanas, representando um acréscimo de 16,6 milhões de habitantes em relação a 2010 [2], o que intensifica a verticalização das construções e a complexidade das soluções de fundação adotadas.

Entre as alternativas de fundações rasas, as sapatas isoladas apresentam ampla aplicação em edificações de pequeno e médio porte, em função de sua simplicidade construtiva e viabilidade econômica. Entretanto, o dimensionamento dessas fundações, na prática corrente, ainda é predominantemente conduzido por procedimentos empíricos e iterativos, baseados em tentativas sucessivas até o cumprimento dos critérios normativos. Tal abordagem depende fortemente da experiência do projetista e, em geral, conduz a soluções conservadoras, com consumo elevado de concreto e consequente aumento dos custos de execução [3]. Além disso, os métodos tradicionais raramente integram, de forma sistemática e simultânea, as restrições estruturais, geotécnicas e geométricas, o que se configura como uma limitação crítica em projetos urbanos com múltiplas interferências espaciais entre elementos de fundação.

Além das dificuldades técnicas, o setor da construção civil enfrenta pressões crescentes para reduzir sua pegada de carbono. O concreto é um dos materiais de maior impacto ambiental, sendo que apenas a descarbonatação do calcário durante a produção do cimento responde por cerca de 6 % das emissões nacionais de dióxido de carbono [4]. O transporte de materiais e as etapas construtivas também contribuem significativamente para esse cenário. Assim, o desenvolvimento de projetos de fundações que utilizem menor volume de concreto representa uma estratégia direta de mitigação dos impactos ambientais, sem comprometer os requisitos de segurança e desempenho estrutural.

Diante desse contexto, ferramentas computacionais de otimização têm se mostrado alternativas promissoras para o dimensionamento de elementos estruturais. Essas ferramentas permitem automatizar análises complexas e integrar critérios de projeto em um único modelo. Estudos recentes [3, 5, 6] evidenciam que o uso de técnicas de otimização conduz a soluções mais eficientes do que as obtidas por métodos convencionais, possibilitando reduções expressivas no consumo de concreto e nas emissões de carbono, além de ampliar a vida útil das estruturas. Essas metodologias também favorecem a padronização do processo de dimensionamento e reduzem a subjetividade associada à experiência individual do projetista.

Entre as técnicas de otimização disponíveis, as metaheurísticas destacam-se pela capacidade de explorar amplos espaços de busca e lidar com problemas altamente não lineares. O Algoritmo Genético (AG), em particular, tem demonstrado excelente desempenho em aplicações de engenharia estrutural, apresentando alta precisão e convergência eficiente com esforço computacional reduzido [7]. Essa abordagem permite avaliar simultaneamente múltiplas variáveis e restrições, conciliando critérios de segurança, economia e sustentabilidade. Além disso, o uso de algoritmos evolutivos favorece a incorporação de diferentes cenários de carregamento e incertezas associadas às propriedades do solo e dos materiais, ampliando a robustez das soluções obtidas.

Assim, a aplicação de estratégias de otimização baseadas em metaheurísticas representa um avanço relevante para o dimensionamento geométrico de sapatas isoladas. A integração entre parâmetros estruturais, geotécnicos e normativos em um ambiente computacional possibilita identificar dimensões economicamente ótimas, reduzindo o consumo de materiais e os impactos ambientais, sem comprometer a segurança da estrutura.

Dessa forma, o presente trabalho propõe uma metodologia de otimização mono-objetivo, fundamentada em metaheurísticas evolutivas, para o dimensionamento automático de sapatas isoladas rígidas. O modelo desenvolvido integra, de forma simultânea, restrições geométricas, geotécnicas e de resistência previstas nas normas técnicas brasileiras. O objetivo consiste em minimizar o volume total de concreto empregado e, conseqüentemente, os custos e os impactos ambientais associados. Com isso, pretende-se contribuir para o avanço das práticas de projeto de fundações, promovendo maior eficiência, sustentabilidade e racionalização no uso dos recursos estruturais.

2. Projeto de sapatas

Nesta seção, são apresentadas as equações utilizadas para o dimensionamento geométrico dos elementos de fundação, que fundamentam a formulação das funções de restrição empregadas no processo de otimização (ver Seção 4). Tais equações visam assegurar o atendimento aos critérios técnicos e normativos brasileiros estabelecidos pela NBR 6118 [8] e pela NBR 6122 [9].

2.1. Tensão normais no solo

A tensão resistente, ou tensão admissível do solo (σ_{adm}), é definida em função das características geotécnicas do terreno, sendo dependente principalmente do tipo de solo. Na prática, é comum a adoção de correlações empíricas baseadas no índice de resistência à penetração obtido por meio do ensaio SPT (*Standard Penetration Test*), amplamente empregado em investigações geotécnicas no Brasil. Nesse contexto, as Equações (1) a (3) apresentam as expressões adotadas neste trabalho para determinar a tensão admissível do solo em função do tipo de material identificado:

$$\sigma_{adm} = \frac{N_{spt}}{50} \cdot 1000 \quad \text{Silte ou argila,} \quad (1)$$

$$\sigma_{adm} = \frac{N_{spt}}{40} \cdot 1000 \quad \text{Areia,} \quad (2)$$

$$\sigma_{adm} = \frac{N_{spt}}{30} \cdot 1000 \quad \text{Pedregulho.} \quad (3)$$

Nessas expressões, N_{spt} ¹ é o valor obtido no ensaio *SPT* (*Standard Penetration Test*) o coeficiente multiplicativo de 1000 é utilizado para a conversão da tensão admissível para a unidade de quilopascal (*kPa*).

A tensão de na sapata é calculada em função da tensão causada pelo esforço vertical (σ_{Fz}), e pelos momentos fletores, em módulo, atuantes nas direções x e y (M_{xk} e M_{yk}), conforme as Equações (4) e (5):

$$\sigma_{max} = \sigma_{Fz} \cdot \left(1 + \frac{6 \cdot |M_{xk}|}{F_{zk} \cdot h_x} + \frac{6 \cdot |M_{yk}|}{F_{zk} \cdot h_y} \right), \quad (4)$$

¹ N_{spt} : Numero de golpes obtido no ensaio *SPT* (*Standard Penetration Test*) para cravar os últimos 30 cm do amostrador para cada metro de sondagem. Valores tipicamente entre 2 e 40 para solos argilosos e siltosos. Fórmula válida para $N_{spt} \leq 20$.

$$\sigma_{\min} = \sigma_{Fz} \cdot \left(1 - \frac{6 \cdot |M_{xk}|}{F_{zk} \cdot h_x} - \frac{6 \cdot |M_{yk}|}{F_{zk} \cdot h_y} \right). \quad (5)$$

75 A tensão vertical σ_{Fz} é definida pela Equação (6), onde o coeficiente 1,05 refere-se ao acréscimo
 76 de tensão para corresponder ao peso próprio do elemento estrutural (ABNT, 2022). As variáveis
 77 h_x e h_y são, respectivamente, as dimensões da sapata em x e y . Os esforços F_{zk} , M_{xk} e M_{yk} são
 78 provenientes da superestrutura e são transferidos aos elementos de fundação por meio dos pilares.
 79 O fator 6 é uma constante geométrica que surge do módulo de resistência elástico de uma seção
 80 retangular.

$$\sigma_{Fz} = \frac{1,05 \cdot F_{zk}}{h_x \cdot h_y}. \quad (6)$$

81 A determinação da tensão atuante em cada sapata, necessita-se considerar todas as combinações
 82 de esforços provenientes da superestrutura. A partir dessas combinações, identifica-se aquela que
 83 resulta na condição mais desfavorável de solicitação, a qual será utilizada no dimensionamento da
 84 fundação.

85 Para garantir a viabilidade técnica da solução de fundação, as tensões solicitantes devem ser in-
 86 feriores à tensão admissível do solo, atendendo aos critérios normativos de segurança e desempenho.
 87 Para as tensões de compressão (positivas), aplica-se um coeficiente de ponderação de 1,30 para a
 88 obtenção da tensão de cálculo. Já para as tensões de tração (negativas), adota-se o fator 1,00, uma
 89 vez que esforços de tração não são admitidos na interface solo-fundação.

90 2.2. Projeto geométrico

91 A verificação geométrica consiste na imposição de uma restrição dimensional mínima entre a
 92 sapata e o pilar. Para cada direção principal x e y , neste trabalho, exige-se que a dimensão da
 93 sapata seja superior à dimensão correspondente do pilar, acrescida de uma folga δ de cada lado,
 94 conforme as Equações (7) e (8):

$$h_x \geq a_p + 2 \cdot \delta, \quad (7)$$

$$h_y \geq b_p + 2 \cdot \delta, \quad (8)$$

95 em que h_x e h_y representam as dimensões da sapata em planta, enquanto a_p e b_p correspondem
 96 às dimensões do pilar.

97 2.3. Sobreposição de fundações

98 É essencial garantir que as sapatas não se sobreponham entre si, uma vez que a sobreposição
 99 inviabilizaria a execução e o desempenho estrutural, exigindo alternativas como sapatas associadas
 100 (que não são contempladas neste trabalho) ou reorganização dos elementos de fundação. Para evitar
 101 a ocorrência de sobreposição geométrica do arranjo de fundações, é considerada uma verificação de
 102 sobreposição entre as sapatas, modeladas como retângulos alinhados aos eixos cartesianos. Ocorre
 103 sobreposição quando duas sapatas ocupam a mesma posição no plano, tal como apresentado na
 104 Figura 1.




Figure 1: Área de sobreposição entre duas sapatas.

105

Cada sapata é definida pelas coordenadas de seus vértices através das Equações (9) a (16).

$$x_{1,i} = x_{g,i} - \frac{h_{x,i}}{2}, \quad (9)$$

$$y_{1,i} = y_{g,i} - \frac{h_{y,i}}{2}, \quad (10)$$

$$x_{2,i} = x_{g,i} + \frac{h_{x,i}}{2}, \quad (11)$$

$$y_{2,i} = y_{g,i} - \frac{h_{y,i}}{2}, \quad (12)$$

$$x_{3,i} = x_{g,i} + \frac{h_{x,i}}{2}, \quad (13)$$

$$y_{3,i} = y_{g,i} + \frac{h_{y,i}}{2}, \quad (14)$$

$$x_{4,i} = x_{g,i} - \frac{h_{x,i}}{2}, \quad (15)$$

$$y_{4,i} = y_{g,i} + \frac{h_{y,i}}{2}. \quad (16)$$

106 A partir da análise simultânea de dois elementos de sapatas, chamadas de i e j , é possível
 107 identificar o comprimento de sobreposição, denominado *overlap*, para as direções x e y , obtidos
 108 através das Equações (17) e (18).

$$\text{overlap}_x = \max(0, \min(x_{i,\max}, x_{j,\max}) - \max(x_{i,\min}, x_{j,\min})), \quad (17)$$

$$\text{overlap}_y = \max(0, \min(y_{i,\max}, y_{j,\max}) - \max(y_{i,\min}, y_{j,\min})). \quad (18)$$

109 A área de sobreposição é obtida pelo produto dos comprimentos *overlap*, apresentado na Equação
 110 (19). Esse valor é utilizado na penalização de sobreposição.

$$A_{\text{overlap}} = \text{overlap}_x \cdot \text{overlap}_y. \quad (19)$$

111 2.4. Punção

112 A verificação da punção será realizada conforme prescrito pela NBR 6118 para elementos estru-
 113 turais de concreto armado [8]. Esse procedimento consiste na análise da resistência ao cisalhamento
 114 em superfícies críticas sucessivas, definidas no entorno da região de aplicação do carregamento do
 115 pilar.

116 O esforço de punção atua em dois perímetros críticos, designados por C e C' , conforme ilustrado
 117 na Figura 2. O perímetro C corresponde ao contorno do pilar enquanto C' indica a região crítica
 118 localizada a uma distância de $2d$ da borda do pilar, sendo d a altura útil da sapata.




Figure 2: Perímetro crítico

119 A resistência da seção C é determinada pela Equação (20)

$$\tau_{rd2} = 0,27 \cdot f_{cd} \cdot \alpha_{v2}, \quad (20)$$

120 em que f_{cd} , a resistência de cálculo do concreto, é dado pela Equação (21)

$$f_{cd} = \frac{f_{ck}}{1,40}, \quad (21)$$

121 α_{v2} é definido pela Equação (22), utilizando o valor de f_{ck} em MPa

$$\alpha_{v2} = 1 - \frac{f_{ck}}{250}. \quad (22)$$

O cálculo da tensão solicitante de cálculo é dada pela Equação (23).

$$\tau_{sd2} = \frac{F_{zk} \cdot 1.4}{2 \cdot (a_p + b_p) \cdot d}, \quad (23)$$

em que d é a altura útil, obtida pela Equação (24), onde cob indica o cobrimento mínimo da armadura.

$$d = h_z - cob. \quad (24)$$

3. Otimização baseada em aprendizado de máquina

A otimização híbrida surge como uma abordagem eficaz para lidar com problemas de otimização global caracterizados por funções objetivo de elevado custo computacional. Nesses cenários, a aplicação direta de métodos clássicos de otimização torna-se impraticável, motivando o desenvolvimento de estratégias que reduzam o número de avaliações reais da função [10, 11].

O princípio fundamental da otimização híbrida consiste na combinação de modelos aproximados (*surrogates*) com estratégias de busca global. Em particular, a maior parte das avaliações diretas da função objetivo é substituída por previsões fornecidas por um modelo de baixo custo computacional, enquanto avaliações reais são realizadas de forma seletiva e orientada. Essa estratégia permite reduzir significativamente o custo computacional total do processo de otimização, sem comprometer a capacidade de exploração global do espaço de busca [10].

Neste trabalho, adota-se uma estratégia híbrida de otimização baseada em aprendizado de máquina, fundamentada no método *Efficient Global Optimization* (EGO). Esta abordagem será combinada com um algoritmo genético para assegurar a convergência a um ótimo global da função mono-objetivo.

3.1. Problema mono-objetivo

Um problema de otimização mono-objetivo (*SOO – Single Objective Optimization*) busca um resultado ótimo em um ponto do espaço de projeto que minimiza (ou maximiza) apenas uma função objetivo [12]. Semelhante aos problemas multiobjetivos, a formulação de um problema mono-objetivo inclui um conjunto de restrições. Essas restrições representam condições que qualquer solução considerada viável deve obrigatoriamente satisfazer. Desse modo, a busca pela solução ótima ocorre apenas dentro do espaço de soluções que atendam às restrições estabelecidas. O conjunto de equações representado em (25) apresenta a forma genérica de um problema mono-objetivo:

$$\begin{cases} \min f(\mathbf{X}), \\ g_i(\mathbf{X}) \leq 0, \quad i = 1, 2, \dots, J, \\ h_j(\mathbf{X}) = 0, \quad j = 1, 2, \dots, K, \\ x_i^L \leq x_i \leq x_i^U, \quad i = 1, 2, \dots, n. \end{cases} \quad (25)$$

A formulação envolve uma função objetivo $f(\mathbf{X})$, onde $\mathbf{X}$ representa o vetor das variáveis de projeto. As inequações $g_j(\mathbf{X})$, as equações $h_k(\mathbf{X})$ e os limites laterais x_i^L e x_i^U correspondem às restrições que delimitam o espaço de busca viável. Os índices j , k e i identificam, respectivamente, as restrições de desigualdade, de igualdade e o intervalo de busca, enquanto J , K e n representam as quantidades totais desses elementos.

3.2. Efficient Global Optimization (EGO)

Proposto por Jones, Schonlau e Welch [10], o EGO é um método de otimização global voltado para problemas em que a avaliação da função objetivo tem alto custo computacional. A ideia central do EGO é reduzir o número de avaliações diretas da função *black-box* por meio de um modelo substituto (do inglês *surrogate*), que aprende uma aproximação da função a partir de um conjunto inicial de amostras e é atualizado iterativamente ao longo do processo.

Em cada iteração, o EGO ajusta um modelo probabilístico (tipicamente um Processo Gaussiano/*kriging*) e utiliza uma função de aquisição para decidir qual ponto deve ser avaliado a seguir. Essa função de aquisição quantifica um critério de utilidade que balanceia dois objetivos concorrentes: (i) explorar regiões do espaço de busca, onde a incerteza do modelo é alta (exploração) e (ii) intensificar a busca em regiões promissoras, onde a predição indica valores baixos da função objetivo (intensificação). Uma escolha clássica de função de aquisição no EGO é o *Expected Improvement* (EI), que mede a melhoria esperada em relação ao melhor valor observado até o momento [10, 13].

Na perspectiva de aprendizado de máquina, o EGO pode ser interpretado como uma arquitetura de aprendizado ativo. Diferentemente de abordagens passivas, nas quais o modelo é treinado sobre um conjunto fixo de dados, o EGO seleciona iterativamente novos pontos de amostragem com base em um critério de decisão que maximiza a expectativa de melhoria ou o ganho informacional. Essa interpretação se alinha à literatura de otimização Bayesiana e projeto sequencial de experimentos, na qual funções de aquisição são tratadas como utilidades para decidir novas avaliações com orçamento limitado [13–15].

Esse tipo de abordagem também aparece em aplicações recentes de projeto computacional: Deng Paulson e Messner ([16]) propõem um método *gradient-free* para o projeto de metamateriais que usa a Regressão por Processo Gaussiano (GPR) para representar o campo de densidade, comprime a representação (matriz de covariância) para reduzir a dimensionalidade e, no espaço comprimido, emprega um método de *active learning* (BADs — *Bayesian Adaptive Direct Search*) para explorar o espaço de projeto de forma eficiente [16].

3.3. Regressão por Processo Gaussiano (GPR)

No contexto do EGO, o modelo substituto é tipicamente formulado por meio de Regressão por Processo Gaussiano (GPR), também associada à tradição de *kriging* na literatura de experimentos computacionais e superfícies de resposta [10, 13]. Diferentemente de modelos paramétricos, que assumem previamente uma forma funcional fixa, o GPR adota uma perspectiva Bayesiana não paramétrica, na qual se define uma distribuição de probabilidade sobre funções. Essa característica é particularmente adequada em problemas de otimização nos quais a função objetivo é desconhecida, cara de avaliar e pode apresentar comportamento não linear ou multimodal [13, 14, 17].

Formalmente, assume-se que a função latente $f(\mathbf{x})$ segue um processo gaussiano,

$$f(\mathbf{x}) \sim \mathcal{GP}(m(\mathbf{x}), k(\mathbf{x}, \mathbf{x}')), \quad (26)$$

em que $m(\mathbf{x})$ é a função média e $k(\mathbf{x}, \mathbf{x}')$ é a função de covariância, ou *kernel*. No GPR, o *kernel* desempenha papel central, pois é ele que define a estrutura de dependência entre os pontos do espaço de entrada. Em termos de modelagem, deseja-se especificar covariâncias de modo que pontos com entradas próximas produzam previsões semelhantes [17]. Assim, o *kernel* codifica hipóteses iniciais sobre regularidade, suavidade e escala de variação da função, além de controlar como a informação observada em um ponto se propaga para regiões vizinhas do domínio [14, 17]. Em problemas práticos, as observações podem ser descritas por

$$y = f(\mathbf{x}) + \varepsilon, \quad (27)$$

onde ε representa ruído observacional, usualmente modelado como gaussiano [13, 14].

Dado um conjunto de dados $D = \{X, \mathbf{y}\}$, o GPR fornece, para qualquer ponto não observado $\mathbf{x}$, uma distribuição preditiva gaussiana caracterizada por média $\mu(\mathbf{x})$ e variância $\sigma^2(\mathbf{x})$. Na forma clássica, a predição posterior pode ser escrita como

$$\mu(\mathbf{x}) = K(\mathbf{x}, X)(K(X, X) + \sigma_\varepsilon^2 I)^{-1} \mathbf{y}, \quad (28)$$

$$\sigma^2(\mathbf{x}) = k(\mathbf{x}, \mathbf{x}) - K(\mathbf{x}, X)(K(X, X) + \sigma_\varepsilon^2 I)^{-1} K(X, \mathbf{x}), \quad (29)$$

em que $K(X, X)$ é a matriz de covariância entre os pontos amostrados [17]. A média preditiva expressa a melhor estimativa do valor da função, enquanto a variância quantifica a incerteza associada ao modelo em cada região do domínio. Como ambas dependem diretamente da função de covariância, a escolha do *kernel* afeta simultaneamente a qualidade da aproximação e a forma como a incerteza é distribuída no espaço de busca [17].

Essa quantificação explícita de incerteza é precisamente o que torna o GPR particularmente apropriado para o EGO. Como a otimização Bayesiana é um procedimento sequencial baseado em modelo probabilístico, o *surrogate* precisa não apenas aproximar a função objetivo, mas também indicar onde essa aproximação é menos confiável [13]. Nesse sentido, $\mu(\mathbf{x})$ sustenta a intensificação em regiões promissoras, ao passo que $\sigma(\mathbf{x})$ viabiliza a exploração de regiões ainda pouco conhecidas. No EGO, essa dualidade é explorada por funções de aquisição como o *Expected Improvement*, que utilizam simultaneamente predição e incerteza para decidir a próxima avaliação cara da função [10, 13].

Além disso, o desempenho do GPR depende da escolha do *kernel* e de seus hiperparâmetros. Em Williams e Rasmussen, por exemplo, os parâmetros da covariância controlam a escala das correlações locais, a contribuição de componentes lineares e de viés, bem como a variância do ruído; em particular, diferentes pesos por dimensão permitem refletir a relevância relativa de cada variável de entrada [17]. Assim, no EGO, o GPR atua como um *surrogate* probabilístico capaz de combinar flexibilidade funcional, interpolação não linear e quantificação de incerteza, reduzindo o número de avaliações reais necessárias em problemas de otimização de alto custo computacional [10, 13].

3.4. Critério de aquisição: Expected Improvement (EI)

Considere um conjunto de amostras $X = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$ e respostas $Y = \{y_1, \dots, y_n\}$, obtidas ao avaliar a função cara $F(\cdot)$ a ser minimizada. Denote o melhor valor observado por:

$$f_{\min} = \min\{y_1, y_2, \dots, y_n\}. \quad (30)$$

Assumindo que o *surrogate* fornece, para cada $\mathbf{x}$, uma distribuição preditiva normal

$$Y(\mathbf{x}) \sim \mathcal{N}(\mu(\mathbf{x}), \sigma^2(\mathbf{x})), \quad (31)$$

em que $Y(\mathbf{x})$ é a variável aleatória que modela o valor da função objetivo real. $\mathcal{N}$ Indica que a distribuição é normal (gaussiana), $\mu(\mathbf{x})$ representa a melhor estimativa do modelo para o valor da função objetivo. $\sigma^2(\mathbf{x})$ é a variância da distribuição preditiva. Sua raiz quadrada, $\sigma(\mathbf{x})$, é o desvio padrão, que quantifica a incerteza do modelo. Em seguida define-se a melhoria aleatória

$$I(\mathbf{x}) = \max(f_{\min} - Y(\mathbf{x}), 0), \quad (32)$$

e a função de aquisição como sua esperança:

$$\text{EI}(\mathbf{x}) = \mathbb{E}[I(\mathbf{x})]. \quad (33)$$

No caso gaussiano, obtém-se uma forma fechada [10] para a função de aquisição:

$$EI(\mathbf{x}) = (f_{\min} - \mu(\mathbf{x})) \Phi\left(\frac{f_{\min} - \mu(\mathbf{x})}{\sigma(\mathbf{x})}\right) + \sigma(\mathbf{x}) \phi\left(\frac{f_{\min} - \mu(\mathbf{x})}{\sigma(\mathbf{x})}\right), \quad (34)$$

onde $\Phi(\cdot)$ e $\phi(\cdot)$ são, respectivamente, a CDF (*Cumulative Distribution Function*) e a PDF (*Probability Density Function*) da normal padrão. A Equação (34) é o ponto-chave: o termo com $\Phi(\cdot)$ favorece intensificação quando a média predita melhora $f_{\min}$, enquanto o termo com $\phi(\cdot)$ cresce com $\sigma(\mathbf{x})$, favorecendo exploração em regiões incertas [10, 13].

3.5. Otimizador interno

Uma vez construído o modelo substituto (*surrogate model*), a maximização do *Expected Improvement* (EI) que é expresso pela Equação (34) é conduzida por um otimizador interno baseado em metaheurística. Neste trabalho, adotou-se um Algoritmo Genético (AG), implementado por meio da biblioteca MEALPY [18, 19], cujos fundamentos e parametrização são descritos a seguir.

O Algoritmo Genético é uma metaheurística inspirada nos mecanismos da evolução natural e na seleção darwiniana [20]. Seu funcionamento básico consiste em evoluir iterativamente uma população de soluções candidatas (indivíduos) por meio dos operadores de **seleção**, **cruzamento** e **mutação**, preservando as características mais promissoras ao longo das gerações. Um fluxograma esquemático do processo é apresentado na Figura 3.




Figure 3: Fluxograma representativo do Algoritmo Genético.

O AG inicia com uma população aleatória de indivíduos, cada um representando um ponto no espaço de busca. A cada geração, os indivíduos são avaliados segundo uma função de aptidão. Os mais aptos têm maior probabilidade de serem selecionados para reprodução, gerando novos indivíduos que gradualmente convergem para regiões de maior interesse.

3.5.1. Operadores genéticos adotados

Seleção por roleta: Utilizou-se o método da roleta (*roulette wheel selection*), no qual cada indivíduo recebe uma probabilidade de seleção proporcional à sua aptidão relativa. Isso permite que indivíduos menos aptos ainda possam ser escolhidos, mantendo a diversidade populacional e reduzindo o risco de convergência prematura [21].

Cruzamento linear: Dois indivíduos selecionados p_0 e p_1 são combinados para gerar três descendentes por combinação linear de suas variáveis de projeto:

$$\begin{aligned} des_{a,k} &= 0,50 \cdot p_{0,k}^t + 0,50 \cdot p_{1,k}^t, \\ des_{b,k} &= 1,50 \cdot p_{0,k}^t - 0,50 \cdot p_{1,k}^t, \\ des_{c,k} &= -0,50 \cdot p_{0,k}^t + 1,50 \cdot p_{1,k}^t, \end{aligned} \quad (35)$$

onde k indica a k -ésima variável e t a geração atual. O melhor descendente é então selecionado para compor a nova população:

$$\mathbf{x}^{(t+1)} = \arg \min \{ des_{a,k}, des_{b,k}, des_{c,k} \}. \quad (36)$$

Mutação por *hill-climbing* com perturbação gaussiana: Para explorar regiões vizinhas à solução atual, aplica-se um operador de mutação baseado em uma perturbação gaussiana:

$$x_{i,k}^{(t+1)} \sim \mathcal{N}(x_{i,k}^t, \sigma), \quad \sigma = x_{i,k}^t \cdot \frac{cov}{100}, \quad (37)$$

em que $\mathcal{N}(\mu, \sigma)$ denota uma distribuição normal com média μ e desvio padrão σ , e cov é um coeficiente de variação definido pelo usuário. Este mecanismo introduz diversidade sem abandonar completamente a informação já acumulada.

3.6. Fluxo operacional do EGO

O EGO executa um ciclo iterativo modelar $\rightarrow$ selecionar $\rightarrow$ avaliar $\rightarrow$ atualizar, como apresentado na Figura 4.




Figure 4: Fluxograma operacional do EGO.

Em forma objetiva, tem-se:

1. **Projeto de Experimentos (DoE – *Design of Experiments*) inicial:** escolher um conjunto inicial X com boa cobertura do domínio (por exemplo, *Latin Hypercube*) e avaliar Y [10].

2. **Treinamento do *surrogate*:** ajustar o modelo probabilístico aos dados (X, Y) para obter $\mu(\mathbf{x})$ e $\sigma(\mathbf{x})$ (ou $\sigma^2(\mathbf{x})$) [10].
3. **Construção da aquisição:** calcular $\text{EI}(\mathbf{x})$.
4. **Escolha do próximo ponto:** resolver

$$\mathbf{x}_{n+1} = \arg \max_{\mathbf{x} \in \mathcal{X}} \text{EI}(\mathbf{x}), \quad (38)$$

em que o termo $\arg \max$ retorna o ponto que maximiza a função. Em seguida avalia $y_{n+1} = F(\mathbf{x}_{n+1})$

5. **Atualização:** incorporar $(\mathbf{x}_{n+1}, y_{n+1})$ ao conjunto e repetir a partir do passo 2 [10].

A iteração prossegue até um orçamento máximo de avaliações ou até que o ganho esperado se torne marginal (por exemplo, $\max_{\mathbf{x}} \text{EI}(\mathbf{x})$ suficientemente pequeno), indicando baixo retorno incremental para novas amostras [10, 13].

4. Metodologia

O dimensionamento otimizado de sapatas é formulado como um problema de otimização com restrições, cujo objetivo é determinar as dimensões geométricas que atendam simultaneamente aos requisitos normativos e de viabilidade construtiva, minimizando o volume total de concreto.

As restrições são expressas como $g_j(\mathbf{X}) \leq 0$, em que valores positivos de g_j representam violações. Para incorporá-las a um esquema de otimização irrestrita, adota-se uma função de penalização quadrática, definida por:

$$P(\mathbf{X}) = \alpha \sum_{j=1}^N \max(0, g_j(\mathbf{X}))^2, \quad (39)$$

onde N é o número de restrições e α é um coeficiente de penalidade, garantindo que soluções inviáveis sejam severamente desfavorecidas.

A função objetivo final $\Theta(\mathbf{X})$ é então composta pelo somatório dos volumes das sapatas, acrescido do termo de penalização:

$$\Theta(\mathbf{X}) = V_{\text{total}}(\mathbf{X}) + P(\mathbf{X}). \quad (40)$$

Dessa forma, o problema original com restrições é transformado em um problema irrestrito de minimização de uma *função pseudo-objetivo* $\Theta(\mathbf{X})$, onde soluções factíveis ($P = 0$) correspondem estritamente à minimização do volume estrutural.

4.1. Restrições de tensões no solo

As restrições associadas as tensões de contato entre a sapata e o solo são formuladas de modo a garantir que as tensões solicitantes máximas e mínimas permaneçam dentro dos limites admissíveis do solo e assim, assegurem que não ocorram tensões maiores que a capacidade do solo, nem tensões de tração no contato entre o solo e a sapata.

A restrição associada à tensão máxima é expressa pela Equação(41):

$$g_{\text{tensao}}^{\text{max}} = \frac{\sigma_{sd}}{\sigma_{adm}} - 1. \quad (41)$$

Da mesma forma, a restrição associada à tensão mínima é dada pela Equação (42). Salienta-se aqui que essa restrição é dada neste formato visto que não será admitida tração neste trabalho.

$$g_{\text{tensao}}^{\text{min}} = \frac{-\sigma_{sd}}{\sigma_{adm}}. \quad (42)$$

4.2. Restrição geometria pilar-sapata

A compatibilidade geométrica em planta é garantida assegurando que as dimensões da sapata excedam as dimensões do pilar somadas à uma folga δ de cada lado do pilar. As Equações (43) e (44) estabelecem essas restrições para as direções x e y , respectivamente.

$$g_{geometria,x} = 1 + \frac{2 \cdot \delta}{a_p} - \frac{h_x}{a_p}, \quad (43)$$

$$g_{geometria,y} = 1 + \frac{2 \cdot \delta}{b_p} - \frac{h_y}{b_p}, \quad (44)$$

em que a_p e b_p representam as dimensões do pilar, h_x e h_y representam as dimensões da sapata, enquanto o valor de δ indica a folga mínima entre o pilar e a lateral do elemento de fundação.

4.3. Restrição de sobreposição

A restrição de sobreposição tem como objetivo impedir que duas ou mais sapatas ocupem, simultaneamente, a mesma posição em planta, condição que inviabilizaria a execução da fundação.

Cada sapata é modelada geometricamente como um retângulo no plano, definido a partir das coordenadas de seus vértices, conforme descrito na Seção 2.3. A partir da interseção geométrica entre dois retângulos, é possível definir a área de sobreposição ($A_{overlap}$) da sapata em análise. Esse valor é então aplicado na restrição definida pela Equação (45), na qual se obtém a razão entre a área de sobreposição da sapata analisada e sua área total em planta.

$$g_{sobreposicao} = \frac{A_{overlap}}{h_x \cdot h_y}. \quad (45)$$

4.4. Restrição de punção

A restrição associada à verificação da punção é formulada a partir da razão entre as tensão solicitante e a tensão admissível de cálculo correspondente, resultando em um valor adimensional ideal para o processo de otimização.

Para a seção crítica junto ao pilar (Seção C), define-se a Equação (46):

$$grd2 = \frac{\tau_{sd2}}{\tau_{rd2}} - 1. \quad (46)$$

4.5. Configurações do algoritmo e métricas de acurácia

A implementação do EGO desenvolvida nesta pesquisa permite flexibilidade na parametrização do processo Gaussiano e na escolha do otimizador interno. Enquanto os hiperparâmetros do Kriging foram calibrados conforme os resultados apresentados na Seção 5, o otimizador interno foi configurado com base em testes preliminares, os valores adotados constam na Tabela 1.

Parâmetro	Valor
Tamanho da população (<i>pop_size</i>)	150
Número de gerações (<i>epoch</i>)	50
Probabilidade de cruzamento (<i>pc</i>)	0,95
Probabilidade de mutação (<i>pm</i>)	0,025

Table 1: Parâmetros do Algoritmo Genético utilizado como otimizador interno.

Embora a arquitetura desenvolvida admita a utilização de qualquer otimizador da biblioteca SCIPY [22] e MEAPLY [18], os resultados reportados neste trabalho restringem-se ao AG, cujo desempenho foi validado preliminarmente. As demais possibilidades de otimizadores não foram exploradas sistematicamente e, portanto, não serão discutidas.

4.5.1. Métricas de avaliação do modelo substituto

Para quantificar a acurácia do modelo substituto (Kriging) em aproximar a função objetivo real, empregou-se o coeficiente de determinação R^2 , definido por:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \quad (47)$$

onde y_i é o valor real da função objetivo no ponto i , $\hat{y}_i$ é o valor predito pelo modelo, $\bar{y}$ é a média dos valores reais e n é o número de pontos avaliados. Um valor de R^2 próximo a 1 indica que o modelo explica a maior parte da variabilidade dos dados.

5. Resultados

Esta seção apresenta os resultados do desenvolvimento da plataforma computacional e da aplicação do modelo de otimização EGO. A análise está organizada em três partes: (a) avaliação do desempenho do modelo substituto (*Kriging*) e sua parametrização; (b) aplicação a um problema ilustrativo de dimensionamento de fundações, detalhando o fluxo de cálculo e a avaliação das restrições; e (c) descrição das funcionalidades da plataforma e da interação do usuário para obtenção de soluções otimizadas.

5.1. Desempenho do modelo substituto

Nesta seção, avalia-se o desempenho de um modelo substituto baseado em Regressão por Processos Gaussianos (GPR) para aproximar a função objetivo associada ao volume da fundações. A análise concentra-se em dois aspectos centrais: (i) o impacto do fator de penalidade aplicado às restrições e (ii) o efeito do aumento do número de amostras no conjunto de treinamento sobre a capacidade preditiva do modelo.

Diferentes funções de covariância (*kernels*) foram avaliadas neste estudo, totalizando dezoito configurações distintas. Nesta seção, são apresentados os resultados referentes ao *kernel* designado como **K06**, o qual consiste em uma variação parametrizada do *kernel Matérn 3/2*.

Inicialmente, investigou-se a influência do fator de penalidade no comportamento da GPR. Para isso, considerou-se o *kernel K06* e um particionamento fixo de dados (70% para treinamento e 30% para teste), variando-se apenas o valor da penalidade aplicada às violações de restrição: uma penalidade suavizada ($\alpha = 10^1$) e uma penalidade elevada ($\alpha = 10^6$). A Figura 5 apresenta os gráficos de dispersão entre os valores observados e preditos para ambos os casos.

Os resultados evidenciam que a adoção de penalidades elevadas induz uma mudança significativa na escala da função objetivo, com volumes penalizados atingindo ordens de grandeza da ordem de 10^6 m^3 . Essa amplificação compromete a capacidade do GPR de capturar a estrutura subjacente do problema, resultando em uma queda substancial no desempenho preditivo, com $R^2_{\text{teste}} \approx 0,69$. Em contraste, a penalidade suavizada permite ao modelo representar adequadamente a relação entre as variáveis de decisão e o volume penalizado, alcançando valores elevados de coeficiente de determinação ($R^2_{\text{teste}} \approx 0,99$). Esses resultados indicam que o fator de penalidade constitui um




Figure 5: Gráficos de dispersão entre volumes observados e preditos pelo modelo GPR para o kernel k06, considerando (a) penalidade suavizada ($\alpha = 10^1$) e (b) penalidade elevada ($\alpha = 10^6$).

hiperparâmetro de grande importância em problemas de aprendizado ativo baseados em modelos substitutos.

Na sequência, foi avaliado o impacto do aumento do conjunto de treinamento no desempenho do GPR. Para essa análise, foram inicialmente testadas diferentes configurações de *kernel* e, com base nas métricas no conjunto de teste, o *kernel K06* foi escolhido como o mais promissor. A Figura 6 ilustra, para essa configuração (representativa do melhor desempenho), os gráficos de dispersão obtidos sob penalidade suavizada ($\alpha = 10^1$) em dois cenários de particionamento: 90%/10% e 60%/40% (treino/teste).

Observa-se que o aumento do número de amostras de treinamento está associado a um incremento no coeficiente de determinação no conjunto de teste (de aproximadamente 0,992 para 0,995). Esse comportamento é consistente com o esperado em modelos estatísticos supervisionados: a ampliação do conjunto de treinamento tende a reduzir incertezas de estimação e a melhorar a aproximação da resposta, desde que as amostras sejam representativas do domínio de interesse.

Por fim, a Tabela 2 consolida as métricas de desempenho (R^2_{test} , MAE e RMSE) para diferentes configurações de *kernel*, considerando penalidade suavizada e múltiplos particionamentos treino/teste ($test_size \in \{0,10, 0,20, 0,30, 0,40, 0,50\}$). Essa análise justifica a escolha do *kernel* adotado nas simulações subsequentes, destacando o desempenho superior do *kernel* k06 no conjunto de teste. Ressalta-se que particionamentos com $test_size$ reduzido (e.g., 0,10) tendem a produzir estimativas de desempenho com maior variabilidade, uma vez que o conjunto de teste se torna menos representativo; por essa razão, a seleção do *kernel* considerou a consistência das métricas ao longo dos diferentes particionamentos.




Figure 6: Gráficos de dispersão entre volumes observados e preditos pelo modelo GPR para o kernel k06, considerando (a) 90%/10% (treino/teste) e (b) 60%/40% (treino/teste).

Kernel	Penalidade	Divisão	Treino	Teste	R^2_{teste}	$\text{MAE}_{\text{teste}}$	$\text{RMSE}_{\text{teste}}$
gpr_com_kernel_k06	10^1	90/10	900	100	0.995	1.769	2.406
gpr_com_kernel_k18	10^1	90/10	900	100	0.996	1.781	2.342
gpr_com_kernel_k05	10^1	90/10	900	100	0.996	1.781	2.342

Table 2: Métricas de desempenho dos modelos GPR para diferentes divisões treino/teste.

5.2. fluxo de cálculo para problema exemplo

Nesta Seção, descrevem-se os resultados da rotina de cálculos implementada no código, utilizados para a verificação do processo de dimensionamento e otimização aplicado a uma sapata submetida a combinações de esforços previamente definidas.

Os dados de entrada considerados no processo, que correspondem às dimensões geométricas dos pilares, às ações provenientes da superestrutura, bem como as características do solo, são apresentados nas Tabelas 3 e 4.

Elemento	a_p (m)	b_p (m)	spt	solo	x_g (m)	y_g (m)
P04	0,30	1,50	35	argila	32,10	20,37
P05	0,25	1,20	45	argila	35,30	20,37
P16	0,25	1,20	43	argila	27,75	18,065

Table 3: Características geométricas e do solo.

O nome e o significado físico de cada uma das variáveis apresentadas estão descritos na Tabela 5.

Com a finalidade de garantir a verificação independente e a rastreabilidade dos resultados, uma das soluções (h_x, h_y, h_z) referente ao elemento P16, obtida ao longo do processo de otimização, foi selecionada e utilizada para a validação manual da rotina de cálculo. Considerando-se, para esta validação, a combinação de carregamento c1.

Elemento	$F_{z,c1}$	$M_{x,c1}$	$M_{y,c1}$	$F_{z,c2}$	$M_{x,c2}$	$M_{y,c2}$	$F_{z,c3}$	$M_{x,c3}$	$M_{y,c3}$
P04	855,5	-3,7	9,2	891,9	-60,0	0,6	908,5	-36,9	0,4
P05	478,6	-3,1	5,0	496,0	-27,6	0,7	508,0	-27,6	0,7
P16	377,3	-1,9	4,4	259,2	-27,8	0,1	383,8	27,7	0,2

Table 4: Cargas atuantes.

Variável	Descrição
x_g	Coordenada do centro de gravidade do pilar na direção x .
y_g	Coordenada do centro de gravidade do pilar na direção y .
a_p	Dimensão do pilar na direção x .
b_p	Dimensão do pilar na direção y .
$F_{z,ci}$	Carga vertical em kPa , atuante no pilar, associada à combinação i .
$M_{x,ci}$	Momento fletor característico em $kN \cdot m$, atuante no pilar, na direção de x , associado à combinação de carregamento i .
$M_{y,ci}$	Momento fletor característico em $kN \cdot m$, atuante no pilar, na direção de y , associado à combinação de carregamento i .

Table 5: Definição das Variáveis

Os elementos P04 e P05 terão seus resultados apresentados, porém, com a explicitação dos cálculos apenas para a verificação de sobreposição. Os valores de h_x , h_y e h_z , referentes aos elementos P16, P04 e P05, bem como os parâmetros necessários para a produção do exemplo, encontram-se na Tabela 6.

Elemento	h_x (m)	h_y (m)	h_z (m)	f_{ck} (MPa)	cob (cm)
P04	4,0	3,5	1,0	25	4
P05	2,7	1,3	1,0	25	4
P16	3,0	3,1	1,0	25	4

Table 6: Valores adotados para o exemplo

É importante frisar que estes valores adotados de h_x , h_y e h_z representam uma solução qualquer dentro do espaço de busca, que pode ser utilizada pelo otimizador em uma das várias tentativas para alcançar o mínimo da função objetivo e, portanto, não necessariamente correspondem a melhor solução para o elemento de fundação.

Utilizando os constantes nas Tabelas 3 e 4, bem como os valores expressos na Tabela 6, obtêm-se os resultados apresentados a seguir

5.2.1. Tensões solo sapata

Dado que o solo na região do pilar P16 é argila, foi empregada a Equação (1) para definição da tensão resistente do solo:

$$\sigma_{adm} = \frac{43}{50} \cdot 1000 = 860,00 \text{ kPa} \quad (48)$$

O valor da tensão devido a carga vertical, σ_{Fzk} , é definido pela Equação (6):

$$\sigma_{fz} = \frac{1,05 \cdot 377,30}{3,00 \cdot 3,10} = 42,60 \text{ kPa} \quad (49)$$

Com base nesse valor, a partir das Equações (4) e (5) são determinadas as tensões solicitantes máxima e mínima de projeto, considerando os efeitos das excentricidades associadas aos momentos causados pela superestrutura.

$$\sigma_{max}^{c1} = 42,60 \cdot \left(1 + \frac{6 \cdot |-1,90|}{377,30 \cdot 3,00} + \frac{6 \cdot 4,40}{377,30 \cdot 3,10} \right) = 43,99 \text{ kPa} \quad (50)$$

$$\sigma_{min}^{c1} = 42,60 \cdot \left(1 - \frac{6 \cdot |-1,90|}{377,30 \cdot 3,00} - \frac{6 \cdot 4,40}{377,30 \cdot 3,10} \right) = 41,21 \text{ kPa} \quad (51)$$

Como as tensões obtidas são positivas, verifica-se que não ocorre efeito de tração entre a fundação e o solo. Portanto os valores são multiplicados por 1,30 conforme descrito na Seção ??.

$$\sigma_{max}^{c1} = 43,99 \cdot 1,30 = 57,18 \text{ kPa} \quad (52)$$

$$\sigma_{min}^{c1} = 41,21 \cdot 1,30 = 53,57 \text{ kPa} \quad (53)$$

Dessa forma, considera-se como referência para checagem da restrição a Equação (41), a qual será aplicada ao resultado de tensão mais crítica, correspondente, neste caso, à tensão máxima atuante:

$$g_{\sigma_{max}}^{c1} = \frac{57,18}{860,00} - 1 = -0,93 \quad (54)$$

$$g_{\sigma_{min}}^{c1} = \frac{53,57}{860,00} - 1 = -0,94 \quad (55)$$

$$\max(g_{\sigma_{max}}^{c1}, g_{\sigma_{min}}^{c1}) = -0,93 \quad (56)$$

Caso ocorram tensões negativas, situação indesejável no projeto de sapatas, estas seriam automaticamente convertidas para um valor de restrição positivo, conforme Equação (42).

A Tabela 7 sintetiza os valores das tensões atuantes no solo para cada combinação de carregamento analisada, tanto para o P16 quanto para os demais elementos, enquanto a Tabela 8 apresenta os resultados das respectivas verificações, formuladas na forma de funções de restrição adotadas no processo de otimização.

Elemento	σ_{max}^{c1} (kPa)	σ_{min}^{c1} (kPa)	σ_{max}^{c2} (kPa)	σ_{min}^{c2} (kPa)	σ_{max}^{c3} (kPa)	σ_{min}^{c3} (kPa)
P04	85.49	81.33	95.84	78.08	94.04	83.12
P05	197.78	174.47	218.00	167.78	222.66	172.45
P16	57.19	53.57	46.23	29.85	64.52	48.14

Table 7: Resultados das tensões máximas e mínimas no solo.

Elemento	$g_{\sigma,\max}^{c1}$	$g_{\sigma,\min}^{c1}$	g_{σ}^{c1}	$g_{\sigma,\max}^{c2}$	$g_{\sigma,\min}^{c2}$	g_{σ}^{c2}	$g_{\sigma,\max}^{c3}$	$g_{\sigma,\min}^{c3}$	g_{σ}^{c3}	g_{σ}
P04	-0.88	-0.88	-0.88	-0.86	-0.89	-0.86	-0.87	-0.88	-0.87	-0.86
P05	-0.78	-0.81	-0.78	-0.76	-0.81	-0.76	-0.75	-0.81	-0.75	-0.75
P06	-0.93	-0.94	-0.93	-0.95	-0.97	-0.95	-0.92	-0.94	-0.92	-0.92

Table 8: Resultado das restrição das tensões solo-sapata.

5.2.2. Punção

É realizada a verificação para a punção no perímetro crítico C . Para tanto, é a determinação da altura útil definida pela Equação (24)

$$d = 1,00 - 0,04 = 0,96 m, \quad (57)$$

em seguida, aplicando-se a Equação (20), obteve-se a tensão resistente à punção no perímetro crítico C

$$\tau_{rd,2} = 0,27 \cdot 17857,14 \cdot \left(1 - \frac{25,00}{250,00}\right) = 4339,98 kPa, \quad (58)$$

na sequencia, por meio da Equação (23) foi calculada a tensão solicitante de punção no perímetro C

$$\tau_{sd,2} = \frac{1,40 \cdot 377,30}{2 \cdot (0,25 + 1,20) \cdot 0,96} = 189,73 kPa. \quad (59)$$

Por fim, a verificação da restrição associada à punção no perímetro C foi realizada a partir da Equação (46), resultando no seguinte valor de restrição

$$g_{rd,2} = \frac{189,73}{4339,98} - 1 = -0,96. \quad (60)$$

Sendo o valor negativo um indicativo de que a tensão solicitante foi inferior à tensão resistente e por isso configura-se atendimento à restrição de punção.

Na Tabela 9 encontram-se os resultados relativos às tensões de punção no perímetro crítico C , enquanto a Tabela 10 mostra os valores das restrições para cada combinação, bem como o valor da restrição mais desfavorável ($g_{pun,C}$).

Elemento	$\tau_{sd,2}^{c1} (kPa)$	$\tau_{rd,2}^{c1} (kPa)$	$\tau_{sd,2}^{c2} (kPa)$	$\tau_{rd,2}^{c2} (kPa)$	$\tau_{sd,2}^{c3} (kPa)$	$\tau_{rd,2}^{c3} (kPa)$
P04	346.56	4339.29	361.30	4339.29	368.03	4339.29
P05	240.68	4339.29	249.43	4339.29	255.46	4339.29
P16	189.73	4339.29	130.34	4339.29	193.00	4339.29

Table 9: Tensões de punção.

5.2.3. Sobreposição

Para a verificação da sobreposição entre as fundações, são considerados os três elementos apresentados na Tabela 3. Aplicando-se os dados desses elementos nas Equações (9) a (16), resulta-se nas coordenadas dos vértices dos retângulos representativos das sapatas, tal como esquematizado pela Figura 1. A seguir, são apresentados os cálculos para o P16:

As coordenadas do vértice 1 são dadas por:

Elemento	g_2^{c1}	g_2^{c2}	g_2^{c3}	$g_{pun,C}$
P04	-0.92	-0.92	-0.92	-0.92
P05	-0.94	-0.94	-0.94	-0.94
P16	-0.96	-0.97	-0.96	-0.96

Table 10: Funções de restrição da verificação à punção.

$$x_1 = 27,75 - \frac{3,0}{2} = 26,25 \text{ m} \quad (61)$$

$$y_1 = 18,065 - \frac{3,1}{2} = 16,52 \text{ m} \quad (62)$$

445 As coordenadas do vértice 2 são dadas por:

$$x_2 = 27,75 + \frac{3,0}{2} = 29,25 \text{ m} \quad (63)$$

$$y_2 = 18,065 - \frac{3,1}{2} = 16,515 \text{ m} \quad (64)$$

446 As coordenadas do vértice 3 são dadas por:

$$x_3 = 27,75 + \frac{3,0}{2} = 29,25 \text{ m} \quad (65)$$

$$y_3 = 18,065 + \frac{3,1}{2} = 19,615 \text{ m} \quad (66)$$

447 E por fim, as coordenadas do vértice 4 são dadas por:

$$x_4 = 27,75 - \frac{3,0}{2} = 26,25 \text{ m} \quad (67)$$

$$y_4 = 18,065 + \frac{3,1}{2} = 19,615 \text{ m} \quad (68)$$

448 Os mesmos cálculos são repetidos para os demais elementos considerados. As coordenadas dos
449 vértices de cada sapata são apresentados na Tabela 11.

Elemento	x_1 (m)	y_1 (m)	x_2 (m)	y_2 (m)	x_3 (m)	y_3 (m)	x_4 (m)	y_4 (m)
P04	30.10	18.62	34.10	18.62	34.10	22.12	30.10	22.12
P05	33.95	19.72	36.65	19.72	36.65	21.02	33.95	21.02
P16	26.25	16.52	29.25	16.52	29.25	19.62	26.25	19.62

Table 11: Coordenadas para a verificação de sobreposição.

450 Com base nos valores obtidos, verificou-se a sobreposição entre os elementos P16 e P04. Para
451 tanto, aplicam-se as Equações (17) e (18), destinadas à determinação das projeções de sobreposição
452 entre os elementos nas direções x e y , respectivamente:

$$\text{overlap}_x = 29,25 - 30,10 = -0,85 \text{ m} < 0 \therefore \text{overlap}_y = 0,00 \text{ m} \quad (69)$$

$$\text{overlap}_y = 19,62 - 18,62 = 1,00 \text{ m} \quad (70)$$

O valor negativo obtido em overlap_x indica a inexistência de sobreposição nessa direção. Consequentemente, a área de sobreposição entre as sapatas analisadas é nula, conforme identificado a seguir por meio da aplicação da Equação (19):

$$A_{\text{overlap}} = 0,00 \cdot 1,00 = 0,00 \text{ m}^2 \quad (71)$$

Desta forma, conclui-se que não há sobreposição entre os elementos P16 e P04. No entanto, em conformidade com a lógica implementada no algoritmo, procede-se ainda à verificação formal da restrição de sobreposição por meio da Equação (45):

$$g_{\text{sobreposicao}} = \frac{0}{3,00 \cdot 3,10} = 0,00 \quad (72)$$

O valor nulo obtido confirma o atendimento à restrição de não sobreposição entre os elementos considerados.

A seguir, aplicou-se a mesma rotina de verificação para o elemento P04 em relação ao P05. Assim, com base nos valores apresentados na Tabela 11, utilizam-se as Equações (17) e (18) para encontrar a sobreposição nas direções x e y , respectivamente:

$$\text{overlap}_x = 34,10 - 22,95 = 0,15 \text{ m} \quad (73)$$

$$\text{overlap}_y = 21,02 - 19,72 = 1,30 \text{ m} \quad (74)$$

Em seguida, pela utilização da Equação (19), obtém-se a área de sobreposição entre os elementos:

$$A_{\text{overlap}} = 0,15 \cdot 1,3 = 0,195 \text{ m}^2 \quad (75)$$

A verificação de sobreposição é realizada por meio da Equação (45), normalizando a área de interseção pela área em planta do elemento P04:

$$g_{\text{sobreposicao}} = \frac{0,195}{4,0 \cdot 3,5} = 0,02 \quad (76)$$

Para a conclusão da verificação, devem ser analisadas todas as interações entre os elementos P16, P04 e P05, considerando-se, inclusive, a verificação mútua entre cada par de elementos (por exemplo, P04–P05 e P05–P04). Contudo, tais cálculos serão omitidos neste trabalho, podendo ser interpretados na Figura 7:


A Tabela 12 apresenta o resultado da verificação de sobreposição através da análise do parâmetro A_{overlap} , como definido na Seção 4.

Elemento	A_{overlap}	$g_{\text{sobreposicao}}$
P04 - P05	0,195	0,02
P04 - P16	0,000	0,00
P05 - P04	0,195	0,06
P05 - P16	0,000	0,00
P16 - P04	0,000	0,00
P16 - P05	0,000	0,00

Table 12: Resultados da verificação de sobreposição.

473 A Figura 7 ilustra graficamente a disposição dos elementos no plano cartesiano e a região de
474 sobreposição:

Figure 7: Representação em planta dos elementos de fundação.



475 5.2.4. Geometria

476 Para a verificação geométrica, aplicam-se as Equações (43) e (44):

$$g_{\text{geometria},x} = 1 + \frac{2 \cdot 0,05}{0,25} - \frac{3,00}{0,25} = -10,6 < 0 \quad (77)$$

$$g_{\text{geometria},y} = 1 + \frac{2 \cdot 0,05}{1,20} - \frac{3,10}{1,20} = -1,5 < 0 \quad (78)$$

477 Os valores negativos obtidos para $g_{\text{geometria},x}$ e $g_{\text{geometria},y}$ indicam que as restrições geométricas
478 são plenamente satisfeitas, uma vez que as dimensões da sapata excedem de forma significativa
479 as dimensões do pilar nas duas direções analisadas. Dessa forma, não há violação das condições
480 geométricas impostas. Os resultados da verificação geométrica nas direções x e y são apresentados
481 na Tabela 13, bem como aquele que configura o pior caso.

Elemento	$g_{\text{geom},x}$	$g_{\text{geom},y}$	g_{geom}
P04	-12,00	-1,27	-1.27
P05	-9,40	0,00	0,00
P16	-10.60	-1.50	-1.50

Table 13: Resultados da verificação de geometria.

482 Nota-se que, para o P05, a restrição $g_{\text{geom},y}$ igual a zero indica que a dimensão adotada chegou
483 ao limiar da viabilidade. Contudo, não configura um descumprimento da restrição.

5.3. O framework FUNDAAI

Neste trabalho, desenvolveu-se a plataforma web **FundaAI** para dimensionamento automatizado de fundações, acessível em <https://fundaai.streamlit.app/>. A ferramenta implementa a metodologia proposta, proporcionando uma interface prática para aplicação em projetos reais. Ela foi implementada em um ambiente STREAMLIT [23], um *framework Python* de código aberto que permite criar aplicativos de dados.

A ferramenta possibilita a importação de uma planilha de dados contendo informações da planta de fundações, incluindo dados geométricos dos elementos, características geotécnicas do solo e combinações de carregamento provenientes da superestrutura, além de parâmetros adicionais definidos diretamente pelo usuário. Esses parâmetros correspondem ao cobrimento (cob) à resistência característica à compressão do concreto (f_{ck}) em MPa e às dimensões máximas e mínimas da sapata ou do conjunto de sapatas a ser dimensionado.

Os parâmetros citados anteriormente referem-se aos parâmetros do modelo mecânico da sapata. Além disso, o usuário define o número de iterações do algoritmo a ser empregado, bem como o tamanho da população que será empregada a cada geração para a busca da solução ótima.

O funcionamento da plataforma envolve, inicialmente, a inserção da planilha de dados e dos parâmetros de dimensionamento pelo usuário. Após essa etapa, a execução do algoritmo é iniciada, realizando assim o dimensionamento geométrico dos elementos de fundação conforme descrito na Seção 2.

Após a conclusão da rotina de cálculos e do processo de dimensionamento, a plataforma disponibiliza duas planilhas de resultados. A primeira contém as dimensões ótimas determinadas para cada elemento analisado e a segunda apresenta o conjunto completo dos valores finais das verificações efetuadas, correspondentes à solução considerada ótima.

Com o objetivo de demonstrar a operacionalidade da ferramenta **FundaAI**, esta seção descreve a interface gráfica da plataforma, detalhando suas funcionalidades e fluxo de interação. Adicionalmente, são apresentados resultados de processos de otimização ilustrativos, baseados no problema-exemplo discutido na seção anterior, que evidenciam a eficácia da abordagem proposta.

A interface da ferramenta foi estruturada de forma intuitiva, de modo a guiar o usuário ao longo das etapas necessárias para a execução do dimensionamento. A Figura 8 apresenta a página inicial, onde pode-se definir o idioma e ver as informações necessárias para o uso, além de baixar um exemplo de arquivo de entrada.

Entrando na aba "Projeto de Sapatas" (ver Figura 9), o usuário tem acesso aos parâmetros que devem ser definidos. Na mesma aba, tem-se o local para inserção da planilha de entrada, em destaque na Figura 10.

Após a inserção dos dados de entrada, o usuário pode iniciar a execução do algoritmo por meio da interface gráfica, como aponta a Figura 11. Durante o processamento, a ferramenta executa automaticamente as rotinas de cálculo conforme descritas ao longo deste trabalho. Ao final da execução, os resultados são apresentados ao usuário de forma organizada conforme mostra a Figura 12 permitindo a visualização das dimensões ótimas obtidas para cada elemento de fundação e a possibilidade de baixar os resultados da rotina para os valores ótimos.

A ferramenta também disponibiliza a exportação dos resultados em formato de planilha, contendo as dimensões finais dos elementos dimensionados, juntamente com o conjunto detalhado das verificações realizadas para a solução ótima (ver Figura 13).

5.3.1. Resultado da otimização

Nesta seção, são apresentados os resultados obtidos após a execução da ferramenta, ou seja, os resultados do dimensionamento otimizado. Para tanto, são empregados diferentes exemplos de



Figure 8: Página inicial da ferramenta *web*.

 Início

 Projeto de Sapatas



Dimensionamento Otimizado de Sapatas



Parâmetros gerais de dimensionamento

Número de combinações	Dimensão mínima da sapata (cm)
3	60,00
fck do concreto (MPa)	Dimensão máxima da sapata (cm)
25,00	300,00
Cobrimento do concreto (cm)	Número de gerações da otimização
4,0	3
	Tamanho da população
	300

Upload da planilha de dados

Selecione o arquivo Excel

 Drag and drop file here
Limit 200MB per file • XLSX, XLS

Browse files

Por favor, selecione um arquivo Excel para continuar.

Figure 9: Pagina de dimensionamento - Local da definição dos parâmetros.




Figure 10: Pagina de dimensionamento - Local de inserção da planilha.




Figure 11: Pagina de dimensionamento - Botão de dimensionamento.




Figure 12: Pagina de dimensionamento - Resultados do dimensionamento.

projetos de fundações para demonstrar a real capacidade de uso do otimizador. Os exemplos são apresentados nas Seções seguintes, juntamente com seus respectivos resultados.

Para os processos de otimização, foi empregado o otimizador EGO (*Efficient Global Optimization*), conforme descrito na Seção 3. Adotou-se uma população inicial de 300 elementos, com um número de gerações fixado em 3. O modelo substituto foi construído a partir de um processo gaussiano, no qual o *kernel* foi definido de acordo com a estratégia apresentada na Seção 5.1.

O problema de fundação consiste em um problema de 3 dimensões que correspondem as dimensões h_x , h_y e h_z da fundação. A função objetivo consiste na minimização do volume total das fundações analisadas, sendo a solução ótima definida pelo conjunto de dimensões que resulta no menor volume admissível, respeitando todas as restrições normativas e geométricas do problema. Todos esses exemplos foram executados pela interface disponível em <https://fundaai.streamlit.app/>.

5.3.1.1. Fundação única


Para este exemplo utilizou-se apenas um único elemento para dimensionamento e otimização. As características do elemento estão expressas nas Tabelas 14 e 15.

Elemento	a_p (m)	b_p (m)	spt	solo	x_g (m)	y_g (m)
P08	2,10	0,25	12	argila	8,13	19,59

Table 14: Características geométricas e do solo para o exemplo de uma fundação.

Aplicando as informações na ferramenta, obtêm-se os valores otimizados: $h_x = 2,94$ m, $h_y = 2,18$ m, $h_z = 0,61$ m e $V = 3,91$ m³. Os valores das restrições² para o resultado encontrado, são

²Os valores das restrições $g \leq 0$ atendem aos critérios, enquanto $g > 0$ indicam desacordo. sendo que:



Elemento	F _{z,c1}	M _{x,c1}	M _{y,c1}	F _{z,c2}	M _{x,c2}	M _{y,c2}	F _{z,c3}	M _{x,c3}	M _{y,c3}
P08	857,40	-0,20	115,60	913,00	-0,90	0,10	950,60	-0,90	-0,50

28

546 apresentados na Tabela ??.

Elemento	$g_{rd,2}^{c1}$	$g_{rd,2}^{c2}$	$g_{rd,2}^{c3}$	g_{σ}^{c1}	g_{σ}^{c2}	g_{σ}^{c3}	g_{geom}
P08	-0,90	-0,89	-0,89	-0,01	-0,19	-0,15	-0,07

Table 16: Resultados das restrições para o problema de uma fundação.

547 Considerando que a viabilidade é satisfeita ao alcançar $g \leq 0$, observa-se na Tabela ?? que todas
 548 as restrições estruturais, geotécnicas e geométricas foram atendidas, não havendo nenhuma violação
 549 das condições impostas pelo problema. Para facilitar a interpretação dos resultados, aplicou-se a
 550 Equação (79), que fornece a razão solicitação/resistência (S/R). Tal equação indica a razão de
 551 solicitação em função da resistência para as restrições que envolvem tensão, enquanto para as
 552 restrições que envolvem geometria, pode-se interpretar como valor necessário e valor permitido.
 553 Os resultados obtidos para todas as restrições são expressos na Tabela 17.

$$\frac{\text{Solicitação}}{\text{Resistência}} = \frac{Sd}{Rd} = g + 1 \quad (79)$$

Elemento	$g_{rd,2}^{c1}$	$g_{rd,2}^{c2}$	$g_{rd,2}^{c3}$	g_{σ}^{c1}	g_{σ}^{c2}	g_{σ}^{c3}	g_{geom}
P08	0,10	0,11	0,11	0,99	0,81	0,85	0,93

Table 17: Razão Solicitação/Resistência (S/R) para as restrições para o problema de uma fundação.

554 No que se refere as tensões de punção $g_{rd,2}^{c1}$, $g_{rd,2}^{c2}$ e $g_{rd,2}^{c3}$, os valores obtidos (-0,90; -0,89; -0,89)
 555 indicam elevada folga de resistência, como pode ser notado ao aplicar a Equação (79), que resulta
 556 em valores na iguais a 0,10 a 0,11, ou seja, a solicitação de punção representa aproximadamente 11%
 557 da resistência disponível. Esse comportamento evidencia que a punção não constitui a condição gov-
 558 ernante do dimensionamento, apresentando uma margem de segurança significativamente superior à
 559 necessária para a viabilidade estrutural. Além disso, os valores para cada combinação apresentaram
 560 leve variação, indicando que a variação de F_{zk} surte pouca influência para essa restrição.

561 Por outro lado, as restrições associadas às tensões no solo obtiveram um comportamento distinto.
 562 A combinação $g_{\sigma}^{c1} = -0,01$ corresponde a uma razão S/R de 0,99, o que caracteriza que tal restrição
 563 teve maior impacto no processo de otimização (uma solicitação de 99% da tensão admissível). As
 564 combinações $c2$ e $c3$, com valores de razão solicitação/resistência de 0,81 e 0,85, apresentam folgas
 565 moderadas, mas substancialmente inferiores as apreciadas na verificação à punção.

566 A restrição geométrica $g_{geom} = -0,07$ também se encontra satisfeita, indicando o atendimento
 567 às exigências, com relativa folga, uma vez que, pela Equação (79), obtém-se uma razão de 0,93, que,
 568 embora represente um valor alto, não ultrapassa a restrição de tensão.

569 A análise percentual das razões S/R entre a restrição mais dominante e a menos solicitada
 570 (Equação (80)) evidencia que a restrição de tensão g_{σ}^{c1} apresenta solicitação 890% superior à verifi-
 571 cada para a restrição de punção $g_{rd,2}^{c1}$, a qual corresponde a mais negativa.

$$\frac{0,99 - 0,10}{0,10} \cdot 100 = 890\% \quad (80)$$

$g_{rd,2}^{ci}$: Restrição associada à verificação de punção na seção C em função da combinação de carga ci ;
 g_{σ}^{ci} : Restrição associada às tensões de contato entre a sapata e o solo para a combinação de carga ci ;
 g_{geom} : Restrição associada à compatibilidade geométrica entre o pilar e a sapata.

Assim, conclui-se que a restrição de tensão solo-sapata g_{σ}^{c1} é a condição governante para o processo de dimensionamento e otimização, sendo responsável por limitar o espaço de busca para as dimensões em planta.

Quando comparada às demais combinações de tensão no solo (Equações (81) e (82)), verifica-se que a combinação $c1$ impõe uma solicitação entre 16,57% e 22,22% superior às combinações $c2$ e $c3$, respectivamente. Esses resultados demonstram, de forma inequívoca, que a condição g_{σ}^{c1} constitui a restrição governante do problema de otimização para essa configuração.

$$\frac{0,99 - 0,81}{0,81} \cdot 100 = 22,22\% \quad (81)$$

$$\frac{0,99 - 0,85}{0,85} \cdot 100 = 16,47\% \quad (82)$$

5.3.1.2. Três elementos de fundação

Para este exemplo, utilizou-se um conjunto de três elementos com o intuito de dimensioná-los e otimizá-los. Tal conjunto corresponde aos elementos do problema tratado na Seção 5.2 deste trabalho e, assim, suas características estão expressas nas Tabelas 3 e 4.

Aplicando as informações na ferramenta *web*, obtém-se os valores otimizados apresentados na Tabela 18. Foram obtidos os valores das restrições para os resultados encontrados são apresentados na Tabela 19.

Elemento	h_x (m)	h_y (m)	h_z (m)	V (m ³)
P04	1,73	2,37	0,60	4,70
P05	0,62	2,72	0,60	1,01
P16	2,61	1,42	0,63	2,33

Table 18: Dimensões finais para o problema de 3 fundações.

Elemento	$g_{rd,2}^{c1}$	$g_{rd,2}^{c2}$	$g_{rd,2}^{c3}$	g_{σ}^{c1}	g_{σ}^{c2}	g_{σ}^{c3}	g_{geom}
P04	-0,86	-0,86	-0,86	-0,58	-0,48	-0,51	-0,45
P05	-0,91	-0,90	-0,90	-0,54	-0,32	-0,31	-0,70
P16	-0,93	-0,95	-0,93	-0,83	-0,86	-0,81	-0,01

Table 19: Resultados das restrições para o problema de 3 fundações.

Aplicou-se a Equação (79) aos valores correspondentes às restrições avaliadas, a fim de construir a Tabela 20, na qual é apresentada a razão S/R para cada verificação.

Elemento	$g_{rd,2}^{c1}$	$g_{rd,2}^{c2}$	$g_{rd,2}^{c3}$	g_{σ}^{c1}	g_{σ}^{c2}	g_{σ}^{c3}	g_{geom}
P04	0,14	0,14	0,14	0,42	0,52	0,49	0,55
P05	0,09	0,10	0,10	0,46	0,68	0,69	0,30
P16	0,07	0,07	0,05	0,07	0,17	0,14	0,99

Table 20: Razão Solicitação/Resistência (S/R) para as restrições do problema de três fundações.

A análise das verificações à punção ($g_{rd,2}^{c1}$, $g_{rd,2}^{c2}$ e $g_{rd,2}^{c3}$) evidencia que a razão S/R apresenta elevada folga de resistência para todas as restrições, com valores compreendidos entre 0,05 e 0,14, ou seja, correspondendo à uma solicitação de no máximo 14% da resistência à punção. Tal resultado indica que a punção não constitui uma condição governante do dimensionamento para esta configuração. Ademais, observa-se pequena variação das restrições entre as combinações de carregamento para um mesmo elemento, reafirmando que a variação de F_{zk} exerce pouca influência sobre essa restrição ou que a dimensão h_z foi suficientemente grande para amortecer os efeitos de tal variação.

Quanto às tensões de contato com o solo, os valores para as verificações situam-se com razão S/R entre 0,07 e 0,69, correspondendo a solicitações de no máximo 69% da capacidade de suporte do solo. Observa-se que o elemento P16 tem valores mais baixos, na faixa de 0,07 a 0,17, enquanto os elementos P04 e P05 encontram-se entre 0,42 e 0,69, indicando que, para estes últimos, o efeito geotécnico foi aproximadamente 306% mais determinante do que para o elemento P16, conforme expresso na Equação (83). Esse resultado evidencia que, para o elemento P05, com 69% de solicitação, tem-se a restrição g_{σ}^{c3} como a mais solicitante entre as restrições geotécnicas.

$$\frac{0,69 - 0,17}{0,17} \cdot 100 = 305,88\% \quad (83)$$

Porém, diferente do problema de uma única fundação, no qual o critério geotécnico era governante no dimensionamento, observa-se que, neste arranjo com três fundações, a limitação geométrica assume um papel determinante no processo de otimização. A restrição g_{geom} apresenta razões S/R iguais a 0,55, 0,30 e 0,99. Nota-se que o elemento P16 encontra-se no limite geométrico, configurando-se como a restrição governante para o arranjo.

A comparação entre a maior razão observada (0,99) e a menor razão global registrada (0,05) resulta em diferença percentual de aproximadamente 1880%, conforme indicado na Equação (84). Tal discrepância reforça a predominância da condição geométrica no controle da solução ótima, evidenciando que o processo de minimização volumétrica conduz o elemento P16 ao limite geométrico antes que as demais verificações se tornem críticas.

$$\frac{0,99 - 0,05}{0,05} \cdot 100 = 1880\% \quad (84)$$

A análise das razões permite observar que apenas um dos três elementos teve restrição que alcançou valor próximo do limite (99% para a restrição geométrica de P16), caracterizando-se como restrição governante. Os demais elementos (P04 e P05) apresentam margens significativas em suas verificações. Esse comportamento demonstra que a formulação adotada conduz a uma solução ótima global, na qual nem todos os elementos atingem o limite individual. Assim, embora P04 e P05 apresentem potencial para a redução de dimensões quando analisados individualmente, tal redução pode não ser significativa para o benefício global.

Por fim, neste arranjo com três elementos, a configuração espacial, com leve grau de proximidade, permitiu que o otimizador evitasse a existência de sobreposição, contrastando com o problema da Seção 5.2 em que foi apresentada sobreposição.

5.3.1.3. Consideração para um regime com elementos sobrepostos

Nesta seção é apresentada a otimização de elementos com alto grau de proximidade, com o objetivo de analisar e demonstrar o comportamento da ferramenta nessas situações específicas. As Tabelas 21 e 22 apresentam os dados iniciais para o dimensionamento.

Elemento	a_p (m)	b_p (m)	spt	solo	x_g (m)	y_g (m)
P01	0,25	1,20	10	argila	6,90	26,255
P02	0,30	1,50	12	argila	7,985	25,105

Table 21: Características geométricas e do solo para o exemplo de duas fundações.

Elemento	F_z^{c1}	M_x^{c1}	M_y^{c1}	F_z^{c2}	M_x^{c2}	M_y^{c2}	F_z^{c3}	M_x^{c3}	M_y^{c3}
P01	485,9	-0,3	4,1	511,6	-32,4	-0,4	511,6	-32,4	-0,4
P02	885,8	-1,0	9,2	912,1	-65,4	0,1	915,9	-40,0	0,1

Table 22: Carregamentos atuantes por combinação

626 Aplicando as informações na ferramenta, foram obtidos os resultados expressos nas Tabelas 23
627 e 24.

Elemento	h_x (m)	h_y (m)	h_z (m)	V (m ³)
P01	2,99	1,40	0,61	2,55
P02	3,00	1,90	0,61	3,48

Table 23: Dimensões finais para o problema de 2 fundações.

Elemento	$g_{\text{sobreposição}}$	$g_{rd,2}^{c1}$	$g_{rd,2}^{c2}$	$g_{rd,2}^{c3}$	g_{σ}^{c1}	g_{σ}^{c2}	g_{σ}^{c3}	g_{σ}	g_{geom}
P01	0,23	-0,90	-0,90	-0,90	-0,18	-0,06	-0,06	-0,06	0,00
P02	0,18	-0,86	-0,86	-0,86	-0,08	0,04	0,00	0,04	-0,1

Table 24: Resultados das restrições para o problema de 2 fundações.

628 A análise da Tabela 24 evidencia que a configuração do problema com duas fundações apresen-
629 tam violação da restrição de sobreposição, com valores de $g_{\text{sobreposição}}$ iguais a 0,23 e 0,18 para os
630 elementos P01 e P02, respectivamente. Como valores positivos indicam a extrapolação do domínio
631 viável, conclui-se que ambas as fundações não satisfazem a questão de sobreposição, indicando que
632 as dimensões em planta interferem entre si no arranjo espacial.

633 Ao analisar a Tabela 25, obtida a partir da aplicação da Equação (79), percebe-se que as veri-
634 ficações à punção estão na faixa de 10 a 14% de solicitação da resistência estrutural, confirmando
635 que essa restrição não exerce influência determinante no dimensionamento para esta configuração.

Elemento	$g_{\text{sobreposição}}$	$g_{rd,2}^{c1}$	$g_{rd,2}^{c2}$	$g_{rd,2}^{c3}$	g_{σ}^{c1}	g_{σ}^{c2}	g_{σ}^{c3}	g_{geom}
P01	1,30	0,10	0,10	0,10	0,82	0,94	0,94	1,00
P02	1,18	0,14	0,14	0,14	0,92	1,04	1,00	0,90

Table 25: Razão Solicitação/Resistência (S/R) para as restrições do problema de duas fundações.

636 Quanto às tensões de contato entre a sapata e o solo, observa-se que o elemento P02 apresenta
637 um valor positivo para a combinação c2, com g_{σ}^{c2} igual a 0,04, o que corresponde uma uma razão

S/R de 1,04, assim caracterizando uma violação da tensão admissível, com uma solicitação de 104% da tensão resistente. As demais verificações de tensão permanecem no domínio viável, com razões S/R entre 0,82 e 1,00, indicando que algumas combinações encontram-se próximas do limite, bem como no limiar da viabilidade, embora não tenham ultrapassado.

Além disso, observa-se que a verificação de geometria apresenta valores de razão S/R na ordem de 0,90 e 1,00, evidenciando que os elementos estão próximos do limite dimensional permitido. Tal comportamento indica que o processo de otimização conduziu as dimensões em planta a valores limítrofes.

Constata-se que, devido ao alto grau de sobreposição entre os elementos, o otimizador reduziu progressivamente as dimensões, aproximando-as do limite geométrico admissível. Entretanto, essa redução implicou no aumento das tensões de contato no solo, culminando na violação observada para o elemento P02. Ainda assim, mesmo com a diminuição das dimensões, a solução obtida não foi suficiente para eliminar completamente a sobreposição, evidenciando um conflito entre as restrições espaciais e geotécnicas na configuração analisada.

Por fim, observa-se que a ferramenta é capaz de identificar a ocorrência de sobreposição entre os elementos de fundação e de buscar alternativas para mitigar essa condição ao longo do processo de otimização. Contudo, devido ao alto grau de sobreposição, a estratégia de alterar as dimensões da sapata não foi suficiente para contornar os efeitos severos da sobreposição. Porém, ao explorar resultados que convergem nas outras restrições, a ferramenta possui potencial para questões de pré dimensionamento.

5.3.2. Comparação de resultados obtidos por força bruta

Realizou-se o dimensionamento dos mesmos elementos aplicados nas Seções 5.3.1.1., 5.3.1.2. e 5.3.1.3., seguindo o método de Monte Carlo (MMC), com o objetivo de reproduzir resultados equivalentes àqueles usualmente obtidos na prática de escritório. Tal prática caracteriza-se pela adoção de procedimentos iterativos baseados em tentativa e erro, nos quais sucessivas combinações de parâmetros são avaliadas até que se obtenham soluções admissíveis segundo os critérios de projeto.

Para alcançar soluções admissíveis pelo MMC foram necessárias 200 tentativas. Em um contexto profissional não necessita-se de tal volume de iterações. Contudo, ainda demandaria elevado esforço técnico, um significativo dispêndio de tempo e um alto grau de organização das planilhas de cálculo. Mesmo diante desse volume de trabalho, o resultado obtido mostrou-se pouco econômico quando comparado aos resultados produzidos pela metodologia de otimização. Ademais, no ambiente de escritório, o tempo disponível e a carga de trabalho do profissional podem influenciar diretamente o resultado final, uma vez que o projetista pode se dar por satisfeito antes de atingir a solução mais eficiente possível. Neste sentido, a Tabela 26 traz a comparação dos resultados obtidos pelo método Monte Carlo e pela metodologia proposta, através da aplicação da Equação (85).

$$\text{Redução percentual (\%)} = \frac{V_{MMC} - V_{otimizado}}{V_{MMC}} \cdot 100 \quad (85)$$

Elemento	$V_{MMC} \text{ (m}^3\text{)}$	$V_{otimizado} \text{ (m}^3\text{)}$	Volume reduzido (%)
P01	5,34	2,55	52,25
P02	4,04	3,48	13,86
P04	3,82	4,70	-23,04
P05	7,15	1,01	85,87
P08	7,72	3,91	49,35
P16	6,94	2,33	66,43

Table 26: Redução dos volumes obtidos pelo metodologia proposta em relação com o método tradicional.

A metodologia proposta demonstra uma clara vantagem ao explorar, de forma sistemática, o espaço de soluções, reduzindo a dependência de decisões subjetivas e conduzindo a resultados significativamente mais econômicos e consistentes na maioria dos elementos, alcançando uma redução média de 40,79%. Contudo, o elemento P04 apresentou desempenho inferior em termos de redução de volume.

6. Conclusão

O objetivo deste trabalho foi desenvolver e avaliar uma ferramenta computacional para o dimensionamento e otimização de fundações superficiais do tipo sapata isolada, integrando critérios estruturais, geotécnicos e geométricos em um único ambiente de projeto. Para tal, foi proposta uma formulação de otimização mono-objetivo baseada na minimização do volume de concreto, empregando restrições normativas e construtivas, resolvida por meio do método *Efficient Global Optimization* (EGO).

Com base nos resultados obtidos, destacam-se as seguintes conclusões:

1. A formulação do problema de dimensionamento como um problema de otimização com restrições mostrou-se adequada para representar, de forma concomitante, os critérios normativos aplicados às sapatas isoladas, incluindo verificações de tensões no solo, punção, compatibilidade geométrica entre o pilar e a sapata, além da sobreposição entre elementos de fundação.
2. O EGO mostrou-se eficiente para problemas com dimensionalidade crescente, como no dimensionamento de múltiplas sapatas, onde cada elemento contribui com três variáveis (h_x , h_y , h_z).
3. A abordagem baseada em modelo substituto garante uma busca global eficaz, como evidenciado pela superioridade frente a amostragem aleatória (Monte Carlo) em termos de qualidade da solução final, validando sua capacidade de evitar convergência prematura para ótimos locais.
4. Os exemplos analisados demonstraram que a metodologia proposta é capaz de convergir para soluções geometricamente proporcionais e tecnicamente viáveis, atendendo simultaneamente às restrições estruturais, geotécnicas e geométricas, além de apresentar uma média de redução de 40,79%, até 85,87%, do consumo de concreto quando comparada a abordagem MMC que representa a técnica de escritório baseada em tentativas sucessivas.
5. A verificação explícita de sobreposição entre sapatas mostrou-se um diferencial relevante do modelo, permitindo identificar interferências geométricas em planta e incorporá-las diretamente ao processo de otimização por meio das funções de restrição normalizadas.
6. Nos casos em que os elementos de fundação apresentam elevado grau de proximidade, os resultados indicaram que a estratégia adotada, baseada apenas na variação das dimensões das

sapatas, pode conduzir a soluções que não convergem para a solução ótima do problema. Isso evidencia que a metodologia, em sua forma atual, é mais adequada a arranjos de fundações sem sobreposição severa. Dessa forma, a sobreposição poderia ser resolvida com a implementação de uma segunda etapa de otimização, na qual a associação das sapatas deve ser verificada.

7. A implementação da metodologia em uma plataforma computacional com interface *web* demonstrou a viabilidade prática da abordagem, permitindo a aplicação direta do modelo em problemas reais de projeto, com entrada de dados via planilha e exportação automatizada dos resultados de dimensionamento e verificação.

8. Em casos com mais de um elemento de fundação, a otimização global do problema não exige que todas as fundações apresentem restrições ativas. Sob a perspectiva de projeto individual, é desejável que cada elemento opere próximo a pelo menos um estado limite, garantindo o aproveitamento eficiente de material e racionalidade construtiva.

De modo geral, a metodologia proposta mostrou-se uma ferramenta eficiente e promissora para o projeto racional e automatizado de sapatas isoladas, contribuindo para a padronização do processo de dimensionamento, a redução da subjetividade do projetista e o uso mais eficiente de materiais. Como trabalhos futuros, recomenda-se a incorporação de abordagens probabilísticas e de análise de confiabilidade, a consideração de sapatas associadas em situações de elevada proximidade entre pilares e a ampliação do modelo para incluir efeitos de recalque, interação solo-estrutura e detalhamento estrutural, de modo a expandir o campo de aplicação da ferramenta desenvolvida.

Declarações

Financiamento

Os autores agradecem o financiamento deste projeto de pesquisa pelo CAPES (processo nº 88887.110529/2025-00).

Conflitos de interesse

Os autores declaram não possuir quaisquer interesses financeiros ou relações pessoais conhecidas que possam ter influenciado o trabalho relatado neste artigo.

Disponibilidade dos dados

As informações necessárias para a reprodução dos resultados apresentados estão disponíveis no próprio artigo. O software desenvolvido internamente e utilizado pelos autores será disponibilizado pelo autor correspondente, wmpjr, mediante solicitação justificada.

Apêndice A. Problema de brinquedo

Não apagar, pois tem formulações referente à punção no perímetro C', que pode ser necessário resgatar!!!

References

- [1] M. G. C. Santos, M. R. S. Corrêa, Analysis of the effects of soil-structure interaction in reinforced concrete wall buildings on shallow foundation, **IBRACON** 11 (2018) 1076–1109.

- [2] IBGE, **Censo demográfico, 2022**, Disponível em: <https://agenciadenoticias.ibge.gov.br/agencia-noticias/2012-agencia-de-noticias/noticias/41901-censo-2022-87-da-populacao-brasileira-vive-em-areas-urbanas>, 2022. Acesso em: 15 ago. 2025.
- [3] M. H. M. Moraes, W. M. Pereira Junior, S. R. M. de Almeida, G. M. Gonçalves Filho, R. F. Vasconcelos, Optimum design of precast and prestressed beams with focus on co2 emission reduction, **IBRACON** 15 (2022) e15006.
- [4] J. F. Santoro, M. Kripka, Determinação das emissões de dióxido de carbono das matérias-primas do concreto produzido na região norte do rio grande do sul, **Ambiente Construído** 16 (2015) 35–49.
- [5] E. Bojórquez Mora, H. Leyva Madrigal, A. Reyes Salazar, E. Fernández González, J. Bojórquez Mora, J. Leal Graciano, J. Serrano Corona, Diseño óptimo multi-objetivo de edificios de concreto reforzado usando algoritmos genéticos, **Revista Ingeniería Sísmica** 99 (2018) 23–47.
- [6] E. V. W. Trentini, G. A. Parsekian, T. N. Bittencourt, Multiobjective optimization of bridge and viaduct design: Comparative study of metaheuristics and parameter calibration, **Engineering Structures** 312 (2024) 118252.
- [7] M. H. Dos Santos, D. C. Oliveira, C. C. Oliveira, L. M. Silva, Estudo do efeito dos parâmetros genéticos de um algoritmo genético na solução otimizada e no tempo de convergência em uma função de duas variáveis, in: **Anais da Conferência de Estudos em Engenharia Elétrica (9 edição)**, Universidade Federal de Uberlândia, Uberlândia – MG, 2013.
- [8] ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS, **ABNT NBR 6118**: Projeto de estruturas de concreto — procedimento, Rio de Janeiro: ABNT, 2023. 256 p.
- [9] ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS, **ABNT NBR 6122**: Projeto e execução de fundações, Rio de Janeiro: ABNT, 2022. 59 p.
- [10] D. Jones, M. Schonlau, W. Welch, Efficient global optimization of expensive black-box functions, *Journal of Global Optimization* 13 (1998) 455–492.
- [11] A. I. J. Forrester, A. Sobester, A. J. Keane, *Engineering Design via Surrogate Modelling: A Practical Guide*, Wiley, 2008.
- [12] F. R. Moreira, Elementos da teoria da otimização mono-objetivo e multiobjetivo: métodos determinísticos e heurísticos, in: **Anais da 27ª Semana do IME/UFG e IV Seminário de Pesquisa e Pós-Graduação do IME/UFG**, Universidade Federal de Goiás, Goiânia, 2016, pp. 78–126. URL: https://www.academia.edu/31361007/Elementos_da_Teoria_da_Otimiza%C3%A7%C3%A3o_Mono_Objetivo_e_Multiobjetivo_M%C3%A9todos_Determin%C3%ADsticos_e_Heur%C3%ADsticos, acesso em: 07 ago. 2025.
- [13] B. Shahriari, K. Swersky, Z. Wang, R. P. Adams, N. de Freitas, Taking the human out of the loop: A review of bayesian optimization, *Proceedings of the IEEE* 104 (2016) 148–175.
- [14] E. Schulz, M. Speekenbrink, A. Krause, A tutorial on gaussian process regression: Modelling, exploring, and exploiting functions, *Journal of Mathematical Psychology* 85 (2018) 1–16.

- 782 [15] J. Snoek, H. Larochelle, R. P. Adams, Practical bayesian optimization of ma-
783 chine learning algorithms, in: F. Pereira, C. Burges, L. Bottou, K. Weinberger
784 (Eds.), Advances in Neural Information Processing Systems, volume 25, Curran Asso-
785 ciates, Inc., 2012. URL: [https://proceedings.neurips.cc/paper_files/paper/2012/file/](https://proceedings.neurips.cc/paper_files/paper/2012/file/05311655a15b75fab86956663e1819cd-Paper.pdf)
786 [05311655a15b75fab86956663e1819cd-Paper.pdf](https://proceedings.neurips.cc/paper_files/paper/2012/file/05311655a15b75fab86956663e1819cd-Paper.pdf).
- 787 [16] H. Deng, N. Paulson, M. C. Messner, Metamaterial design based on autoencoder representation
788 using an active learning method, Structural and Multidisciplinary Optimization 69 (2026) 21.
- 789 [17] C. Williams, C. Rasmussen, Gaussian processes for regression, in: D. Touretzky,
790 M. Mozer, M. Hasselmo (Eds.), Advances in Neural Information Processing Systems, volume 8,
791 MIT Press, 1995. URL: [https://proceedings.neurips.cc/paper_files/paper/1995/file/](https://proceedings.neurips.cc/paper_files/paper/1995/file/7cce53cf90577442771720a370c3c723-Paper.pdf)
792 [7cce53cf90577442771720a370c3c723-Paper.pdf](https://proceedings.neurips.cc/paper_files/paper/1995/file/7cce53cf90577442771720a370c3c723-Paper.pdf).
- 793 [18] N. Van Thieu, S. Mirjalili, Mealpy: An open-source library for latest meta-heuristic algorithms
794 in python, Journal of Systems Architecture (2023).
- 795 [19] N. Van Thieu, S. D. Barma, T. Van Lam, O. Kisi, A. Mahesha, Groundwater level modeling
796 using augmented artificial ecosystem optimization, Journal of Hydrology 617 (2023) 129034.
- 797 [20] J. H. Holland, Adaptation in Natural and Artificial Systems: An Introductory Analysis with
798 Applications to Biology, Control, and Artificial Intelligence, MIT Press, Cambridge, 1992.
- 799 [21] R. Linden, Algoritmos Genéticos, 2 ed., **Brasport**, Rio de Janeiro, 2008.
- 800 [22] P. Virtanen, R. Gommers, T. E. Oliphant, et al., Scipy 1.0: fundamental algorithms for
801 scientific computing in python, Nature Methods 17 (2020) 261–272.
- 802 [23] Streamlit Inc., Streamlit documentation, <https://docs.streamlit.io/>, 2024. Acesso em: 11
803 fev. 2026.